

6. パフォーマンス改善編

性能改善・検証記録

目的

検索性能と動画変換性能について、変更内容だけでなく、測定条件、想定結果、実測結果、判断、再測定方法を同じ記録に残す。

この記録の数値はローカル環境での比較結果であり、Render、Vercel、Cloudflare R2、インターネット回線、Cold Start、同時アクセスを含む本番SLAではない。

その他のPDFは今回の指摘に対応する変更箇所がないため、内容を変更しない。

動画変換の改善履歴

段階	Commit	FFmpegの主要設定	目的
初期実装	<code>8f156193e06d237b069503930c4f18a435027ac9</code>	<code>libx264</code> 、 <code>preset=medium</code> 、 720x1280、30fps、 AAC	公開条件を満たす 再生用MP4を生成 する
通信量制御	<code>72a1e7cc81f1123e7568bf4570bfc0d40d728259</code>	CRF 23、最大 3Mbps、Buffer 6Mbps、Metadataと Chapterを削除	出力容量と配信時 の転送量を抑える
処理負荷軽減	<code>966457cbc37212a29d56b81bdbf236ce6afedce5</code>	<code>preset=veryfast</code> 、 Video Encoder 1 thread	小さいCPU・ Memory環境で Workerの占有を 抑える

現行設定は `backend/repository/media_repository.go` にあり、次の公開条件を維持する。

- MP4 / H.264
- 720×1280
- 30fps以下
- 音声ありの場合はAAC
- Web配信用のFast Start

測定条件

項目	値
測定日	2026-08-16
FFmpeg	6.1.1-3ubuntu5、libx264有効

項目	値
入力	合成動画、10秒、1080x1920、60fps、H.264、AAC
入力容量	47,312,729 bytes
入力Bitrate	37,850,183 bps
実行回数	各段階3回
集計	経過時間とCPU時間はMedian、Memoryは3回中の最大RSS

測定結果

段階	出力容量	入力比削減	経過時間 Median	CPU時間 Median	最大RSS
初期実装	23,424,942 bytes	50.5%	4.621秒	28.638秒	482,844 KiB
通信量制御	4,124,534 bytes (Median)	91.3%	3.252秒	17.864秒	481,924 KiB
現行設定	4,214,913 bytes	91.1%	6.910秒	8.991秒	230,404 KiB

通信量制御段階の出力容量は4,111,519～4,150,262 bytes、Medianは4,124,534 bytesだった。全出力についてFFprobeでMP4、H.264、720x1280、30fps、AACを確認した。

判断

- 通信量制御により、初期実装比で出力容量を82.4%削減した。
- 現行設定は通信量制御段階より経過時間が112.5%増えた一方、CPU時間を49.7%、最大RSSを52.2%削減した。
- 現行設定の狙いは最短処理時間ではなく、Worker同時実行数1の小規模環境でCPUとMemoryの占有を抑えることである。
- 入力容量の上限は、実装と動画投稿・処理・閲覧編に合わせて50,000,000 bytesを正本とする。

実動画、本番相当CPU、同時Job数を変えた場合は、同じ入力と同じFFmpegバージョンで再測定する。

検索Benchmarkの設計

対象コード

- データ生成・削除: `backend/cmd/seed_search_benchmark/main.go`
- API測定・DB実行計画: `backend/scripts/benchmark_search.sh`
- API測定関数: `benchmark_case`
- 集計関数: `summarize_case`
- DB実行計画: `run_explain`

データ生成は `--confirm-local` を必須とし、`ENVIRONMENT=production` では停止する。件数は100、1,000、10,000だけを許可する。

4.2 Benchmark単独データの想定結果

生成件数	公開動画	Output Meta	Like	latte_art	latte-art Title一致
100	100	100	200	20	2
1,000	1,000	1,000	2,000	200	20
10,000	10,000	10,000	20,000	2,000	200

Likeは5人のBenchmark Userへ0件、1件、2件、3件、4件の周期で作成するため、5動画ごとに10件、平均2件となる。

標準Seedには公開動画が25件ある。標準Seedと併用した場合、APIの公開検索対象は次の件数になる。

Benchmark生成件数	標準Seed公開動画	API公開検索対象
100	25	125
1,000	25	1,025
10,000	25	10,025

標準Seedのprivate、hidden、deleted各1件は一般の公開検索対象へ含めない。BenchmarkスクリプトがDB件数として検証するのは、標準Seedを含まないBenchmark専用データの100件、1,000件、10,000件である。

APIケースの想定結果

APIは各ケースで `limit=20` を指定する。

ケース	条件	想定 result_type	Benchmarkデータの一一致件数
条件なし	なし	all	生成件数と同数。Responseは最大20件
Category	category=latte_art	matched	20 / 200 / 2,000件。Responseは最大20件
Title	title=latte-art	matched	2 / 20 / 200件。Responseは最大20件
Title + Category	上記2条件	matched	2 / 20 / 200件。Responseは最大20件
Similarity Fallback	title=latte-artt	similar	候補件数はpg_trgmの閾値と実データに依存するため固定しない

Similarity Fallbackは通常Title一致が0件のときに実行する。想定結果として固定するのは `result_type=similar` であり、候補件数は実測Responseへ記録する。

リクエスト数

既定値は1ケースあたり、Response検証1回、Warm-up 5回、測定100回である。

区分	計算	回数
測定対象	3規模 × 5ケース × 100回	1,500
Warm-up	3規模 × 5ケース × 5回	75
事前Response検証	3規模 × 5ケース × 1回	15
HTTP Call合計	1,500 + 75 + 15	1,590

計測項目

APIではDNS、Connect、TLS、TTFB、Total、HTTP Statusを保存し、ケースごとにp50、p95、max、1秒以上、5秒以上、非200件数を集計する。

PostgreSQLでは次を保存する。

- `EXPLAIN (ANALYZE, BUFFERS)`
- `idx_videos_public_feed`
- `idx_videos_public_category`
- `idx_videos_public_title_trgm`
- Query PlanとIndexの利用状況

検索Benchmarkの実行方法

APIと依存サービスを起動した後、Repositoryルートで実行する。

```
API_BASE_URL=http://localhost:<PORT> \  
./backend/scripts/benchmark_search.sh
```

件数、Warm-up、測定回数を明示する場合は次のように実行する。

```
API_BASE_URL=http://localhost:<PORT> \  
RUNS=100 \  
WARMUP_RUNS=5 \  
SCALES="100 1000 10000" \  
./backend/scripts/benchmark_search.sh
```

結果は `backend/docs/search_performance_results/<timestamp>/` へ出力される。

- `summary.csv`: p50、p95、max、閾値超過、非200件数
- `api_raw.csv`: 各Requestの生値
- `environment.txt`: Commit、OS、Docker Compose、PostgreSQL
- `explain_100.txt`、`explain_1000.txt`、`explain_10000.txt`: DB実行計画
- `_first_response.json`: `result_type` とResponse内容の確認用

現在受け取ったProjectには実測した `search_performance_results` が含まれていない。そのため、p50、p95、maxの数値を推測して記載しない。Benchmark実行後、`summary.csv` と判断をこの文書へ追記する。

合格条件

検索

- Benchmark専用動画、Output Meta、Like件数が想定表と一致する。
- 5ケースの `result_type` が想定表と一致する。

- 測定1,500 Requestが全てHTTP 200で、`non_200=0` となる。
- 100件、1,000件、10,000件の全てでp50、p95、maxを記録する。
- 3つの検索Indexが存在し、各Query Planを保存する。
- 1秒以上、5秒以上の件数を確認し、増加理由をQuery Planと合わせて判断する。

動画

- 50,000,000 bytes以下の入力を受け付け、上限超過を拒否する。
- 出力がMP4、H.264、720x1280、30fps以下を満たす。
- 音声ありの場合はAAC、無音の場合は映像のみのMP4となる。
- Stageごとの `duration_ms`、Job全体の `total_ms`、失敗時の `failure_code` と `retryable` を記録する。
- 大きい負荷の動画について、入力、FFmpeg、Commit、回数、容量、経過時間、CPU時間、最大RSSを同一条件で比較する。